

Trabalho I: Análise bayesiana no caso Normal.

Disciplina: Inferência Estatística
Aluno: Iara Cristina Mescua Castro

24 de agosto de 2022

Data de Entrega: 24 de Agosto de 2022.

Questão 1: Escreva a distribuição conjunta condicional dos dados sob a nova parametrização
Resposta:

$$\begin{aligned} f_n(\underline{x}|\phi) &= \prod_{i=1}^n f(x_i|\phi) = \prod_{i=1}^n \frac{\sqrt{\tau}}{\sqrt{2\pi}} e^{-\frac{\tau(x_i-\mu)^2}{2}} \\ &= \left(\sqrt{\frac{\tau}{2\pi}}\right)^n e^{-\frac{\tau}{2} \sum_{i=1}^n (x_i-\mu)^2} \end{aligned}$$

É possível desconsiderar a constante $(\sqrt{2\pi})^n$:

$$f_n(\underline{x}|\phi) \propto (\sqrt{\tau})^n e^{-\frac{\tau}{2} \sum_{i=1}^n (x_i-\mu)^2}$$

Questão 2: A partir da densidade do item anterior, deduza que a distribuição a priori conjugada conjunta para $\phi = (\mu, \tau)$ da forma

$$\begin{aligned} \tau &\sim \text{Gama}(\alpha_0, \beta_0) \\ \mu|\tau &\sim \text{Normal}(m_0, \lambda_0\tau) \end{aligned}$$

Resposta:

A priori de τ :

$$\xi(\tau) \propto \tau^{\alpha_0-1} e^{-\beta_0\tau}$$

A priori conjunta de $\mu|\tau$

$$\xi(\mu|\tau) \propto \sqrt{\tau} e^{-\frac{\lambda_0\tau}{2}(\mu-m_0)^2}$$

$$\xi(\mu|\tau) = \frac{\xi(\mu, \tau)}{\xi(\tau)} \Leftrightarrow \xi(\phi) = \xi(\mu, \tau) = \xi(\mu|\tau)\xi(\tau)$$

$$\xi(\phi) = \xi(\mu, \tau) = (\sqrt{\tau} e^{-\frac{\lambda_0\tau}{2}(\mu-m_0)^2}) * (\tau^{\alpha_0-1} e^{-\beta_0\tau})$$

$$\xi(\phi) \propto (\tau^{\alpha_0-1} e^{-\beta_0\tau}) * (\sqrt{\tau} e^{-\frac{\lambda_0\tau}{2}(\mu-m_0)^2})$$

$$\xi(\phi) \propto \tau^{\alpha_0-1} e^{-\beta_0\tau} \sqrt{\tau} e^{-\frac{\lambda_0}{2}(\mu-m_0)^2}$$

Fórmula para posteriori conjunta:

$$\xi(\mu, \tau|\underline{x}) \propto \xi(\mu, \tau) \cdot f_n(\underline{x}|\mu, \tau)$$

$$\xi(\phi|\underline{x}) \propto \xi(\phi) \cdot f_n(\underline{x}|\phi)$$

$$\xi(\phi|\underline{x}) \propto \left(\tau^{\alpha_0-1} e^{-\beta_0 \tau} \sqrt{\tau} e^{-\frac{\tau}{2}(\lambda_0(\mu-m_0)^2)} \right) \left((\sqrt{\tau})^n e^{-\frac{\tau}{2} \sum_{i=1}^n (x_i - \mu)^2} \right)$$

$$\xi(\phi|\underline{x}) \propto \tau^{\alpha_0 + \frac{n}{2} - 1} e^{-\beta_0 \tau} \sqrt{\tau} e^{-\frac{\tau}{2}(\lambda_0(\mu-m_0)^2 + \sum_{i=1}^n (x_i - \mu)^2)}$$

Agora precisamos arrumar essa expressão para encontrar uma conjunta de distribuição gama e normal:

Vamos rearranjar os índices da segunda exponencial: $e^{-\frac{\tau}{2}(\lambda_0(\mu-m_0)^2 + \sum_{i=1}^n (x_i - \mu)^2)}$
Abrindo os quadrados:

$$-\frac{\tau}{2}(\lambda_0(\mu^2 - 2\mu + m_0^2) + \sum_{i=1}^n x_i^2 - 2 \sum_{i=1}^n x_i \mu + \sum_{i=1}^n \mu^2)$$

Agora vamos colocar μ^2 e -2μ em evidência. ps.: $\sum_{i=1}^n \mu^2 = n\mu^2$

$$-\frac{\tau}{2}(\mu^2(\lambda_0 + n) - 2\mu(\lambda_0 m_0 + \sum_{i=1}^n x_i) + \sum_{i=1}^n x_i^2 + \lambda_0 m_0^2)$$

Colocando $(\lambda_0 + n)$ em evidência em toda a expressão:

$$-\frac{\tau}{2}((\lambda_0 + n)(\mu^2 - 2\mu \left(\frac{\lambda_0 m_0 + \sum_{i=1}^n x_i}{\lambda_0 + n} \right) + \frac{\sum_{i=1}^n x_i}{\lambda_0 + n} + \frac{\lambda_0 m_0^2}{\lambda_0 + n}))$$

Agora é possível completar quadrados de forma que $\omega = \frac{\lambda_0 m_0 + \sum_{i=1}^n x_i}{\lambda_0 + n}$:

$$-\frac{\tau}{2}((\lambda_0 + n)((\mu - \omega)^2 - \omega^2 + \frac{\sum_{i=1}^n x_i}{\lambda_0 + n} + \frac{\lambda_0 m_0^2}{\lambda_0 + n}))$$

Concluimos que:

$$\xi(\phi|\underline{x}) \propto \tau^{\alpha_0 + \frac{n}{2} - 1} e^{-\beta_0 \tau - \frac{\tau}{2}(\sum_{i=1}^n x_i^2 + \lambda_0 m_0^2 - \frac{(\lambda_0 m_0 + \sum_{i=1}^n x_i)^2}{(\lambda_0 + n)})} \sqrt{\tau} e^{-\frac{\tau}{2}(\lambda_0 + n)(\mu - \omega)^2}$$

$$\xi(\phi|\underline{x}) \propto \tau^{\alpha_0 + \frac{n}{2} - 1} e^{-\beta_0 \tau - \frac{\tau}{2}(\sum_{i=1}^n x_i^2 + \lambda_0 m_0^2 - \frac{(\lambda_0 m_0 + \sum_{i=1}^n x_i)^2}{\lambda_0 + n})} \sqrt{\tau} e^{-\frac{\tau}{2}(\lambda_0 + n)(\mu - \omega)^2}$$

$$\xi(\phi|\underline{x}) \propto \tau^{(\alpha_0 + \frac{n}{2}) - 1} e^{-\tau(\beta_0 + \frac{1}{2}(\sum_{i=1}^n x_i^2 + \lambda_0 m_0^2 - \frac{(\lambda_0 m_0 + \sum_{i=1}^n x_i)^2}{\lambda_0 + n}))} \sqrt{\tau} e^{-\frac{\tau}{2}(\lambda_0 + n)(\mu - \omega)^2}$$

Note que a primeira parte depende apenas de τ , enquanto a segunda parte (a partir de $\sqrt{\tau}$) depende de μ e τ .

Sabendo que $\xi(\mu, \tau) = \xi(\tau)\xi(\mu|\tau) \Leftrightarrow \xi(\phi) = \xi(\tau)\xi(\mu|\tau)$

$$\xi(\phi|\underline{x}) = \xi(\tau|\underline{x})\xi(\mu|\tau, \underline{x})$$

Podemos concluir que:

$$\xi(\tau|\underline{x}) = \tau^{(\alpha_0 + \frac{n}{2} - 1)} e^{-\tau(\beta_0 + \frac{1}{2}(\sum_{i=1}^n x_i^2 + \lambda_0 m_0^2 - \frac{(\lambda_0 m_0 + \sum_{i=1}^n x_i)^2}{\lambda_0 + n}))}$$

$$\xi(\mu|\tau, \underline{x}) = \sqrt{\tau} e^{-\frac{\tau}{2}(\lambda_0 + n)(\mu - \omega)^2}$$

Questão 3: A partir dos itens anteriores, derive a distribuição a posteriori conjunta de μ e τ e a distribuição conjunta de μ dado τ , assim como a distribuição marginal a posteriori de τ .

A partir da questão anterior, obtemos que:

$$\xi(\phi|\underline{x}) \propto \underbrace{\tau^{(\alpha_0 + \frac{n}{2}) - 1} e^{-\tau(\beta_0 + \frac{1}{2}(\sum_{i=1}^n x_i^2 + \lambda_0 m_0^2 - \frac{(\lambda_0 m_0 - \sum_{i=1}^n x_i)^2}{\lambda_0 + n})}}_1 \underbrace{\sqrt{\tau} e^{-\frac{\tau}{2}(\lambda_0 + n)(\mu - \omega)^2}}_2$$

É proporcional às duas distribuições:

1) $\xi(\tau|\bar{x}) = Gama(\alpha_1, \beta_1)$, onde:

$$\alpha_1 = \alpha_0 + \frac{n}{2} \text{ e } \beta_1 = \beta_0 + \frac{1}{2}(\sum_{i=1}^n x_i^2 + \lambda_0 m_0^2 - \frac{(\lambda_0 m_0 - \sum_{i=1}^n x_i)^2}{\lambda_0 + n})$$

2) $\xi(\mu|\tau, \bar{x}) = Normal(m_1, \lambda_1)$, onde:

$$m_1 = \omega = \frac{\lambda_0 m_0 + \sum_{i=1}^n x_i}{\lambda_0 + n} \text{ e } \lambda_1 = \lambda_0 + n$$

Questão 4: Interprete as expressões obtidas no item anterior; o que as formas funcionais obtidas revelam sobre a interação entre os hiperparâmetros e os dados?

Elas revelam que devido o λ_0 em uma pequena quantidade de amostras, faz a distribuição ser mais espalhada já que a variância aumenta. Isso se dá por ser inversamente proporcional à $\xi(\mu|\tau, \bar{x})$. Enquanto em uma grande quantidade de amostras ocorre o contrário, a variância é menor e a distribuição se torna mais concentrada.

Vale ressaltar também que:

$$m_1 = \frac{\lambda_0 m_0 + n\bar{x}}{\lambda_0 + n} = \frac{\lambda_0}{\lambda_0 + n} m_0 + \frac{n}{\lambda_0 + n} \bar{x}$$

Então m_1 é uma média ponderada da média a priori y da média amostral

$$\lambda_1 = \lambda_0 + n \Rightarrow \underbrace{\tau \lambda_1}_{\text{precisao condicional}} = \underbrace{\tau \lambda_0}_{\text{precisao priori}} + \underbrace{\tau n}_{\text{precisao amostral}}$$

Questão 5: Derive a distribuição marginal a posteriori de τ (Dica: leia o capítulo 8.4 de De Groot).

A distribuição marginal a posteriori de τ :

$$\int_a^b \xi(\mu, \tau|\underline{x}) d\mu = \int_a^b \xi(\tau|\underline{x}) \xi(\mu|\tau, \underline{x}) d\mu$$

Como já foi calculado:

$$\begin{aligned} &= \int_0^\infty \tau^{\alpha_1 - 1} e^{-\tau \beta_1} \sqrt{\tau} e^{-\frac{\tau}{2}(\lambda_1)(\mu - m_1)^2} d\tau \\ &= \int_0^\infty \tau^{\alpha_1 + \frac{1}{2} - 1} e^{-\frac{\tau}{2}(2\beta_1 + (\lambda_1)(\mu - m_1)^2)} d\tau \\ &= \int_0^\infty \tau^{\alpha_1 + \frac{1}{2} - 1} e^{-\tau(\beta_1 + \frac{(\lambda_1)}{2}(\mu - m_1)^2)} d\tau \end{aligned}$$

A partir da função Gamma:

$$\begin{aligned}
\Gamma(\alpha) &= \int_0^\infty x^{\alpha-1} e^{-x} \\
\beta x = y &\iff x = \frac{y}{\beta} \iff \beta dx = dy \\
\int_0^\infty x^{\alpha-1} e^{-\beta x} dx &= \int_0^\infty \frac{y^{\alpha-1}}{\beta} e^{-y} \frac{1}{\beta} dy \\
&= \int_0^\infty \frac{1}{\beta^\alpha} y^{\alpha-1} e^{-y} dy \\
\int_0^\infty x^{\alpha-1} e^{-\beta x} dx &= \frac{\Gamma(\alpha)}{\beta^\alpha}
\end{aligned}$$

Então:

$$\begin{aligned}
&= \int_0^\infty \tau^{\overbrace{(\alpha_1 + \frac{1}{2})}^{\alpha_2} - 1} e^{-\tau \overbrace{(\beta_1 + \frac{(\lambda_1)}{2}(\mu - m_1)^2)}^{\beta_2}} d\tau = \int_0^\infty \tau^{\alpha_2-1} e^{-\beta_2 \tau} d\tau \\
&\frac{\Gamma(\alpha_1 + \frac{1}{2})}{(\beta_1 + \frac{(\lambda_1)}{2}(\mu - m_1)^2)^{(\alpha_1 + \frac{1}{2})}} \propto (\beta_1 + \frac{(\lambda_1)}{2}(\mu - m_1)^2)^{-(\alpha_1 + \frac{1}{2})} \\
&\xi(\mu|\underline{x}) \propto (\beta_1 + \frac{(\lambda_1)}{2}(\mu - m_1)^2)^{-(\alpha_1 + \frac{1}{2})} \\
&\xi(\mu|\underline{x}) \propto (1 + \frac{(\lambda_1)}{2\beta_1}(\mu - m_1)^2)^{-(\frac{2\alpha_1+1}{2})}
\end{aligned}$$

Podemos representá-la na forma da distribuição de T-Student, com os parâmetros de locação m_1 , escala $\frac{2\beta}{\lambda_1}$ e $2\alpha_1 = 2\alpha_0 + n$ graus de liberdade.

Em outras palavras:

$$\xi(\mu|\underline{x}) \sim T - Student(v, \mu, \sigma)$$

$$\xi(\mu|\underline{x}) \sim T - Student(2\alpha_1, m_1, \frac{2\beta_1}{\lambda_1})$$

$$\xi(\mu|\underline{x}) \sim T - Student(2\alpha_0 + n, \frac{\lambda_0 m_0 + \sum_{i=1}^n x_i}{\lambda_0 + n}, \frac{2\beta_1}{\lambda_1})$$

Onde $\beta_1 = \beta_0 + \frac{1}{2}(\sum_{i=1}^n x_i^2 + \lambda_0 m_0^2 - \frac{(\lambda_0 m_0 - \sum_{i=1}^n x_i)^2}{\lambda_0 + n})$ e $\lambda_1 = \lambda_0 + n$

Questão 6: Palmirinha anda preocupada com a concentração de amido em sua pamonha. Ela pede para Valciclei, seu assistente, amostrar $n = 10$ pamonhas e medir sua concentração de amido. Ele, muito prestativo, rapidamente faz o experimento, mas, porque comeu todas as amostras depois que foram medidas, precisou fazer uma visita de emergência ao banheiro. Desta feita, apenas teve tempo de anotar em um papel a média e variância amostrais, $\overline{x_n} = 8.307849$ e $\overline{s_n^2} = 7.930452$. Palmirinha tem uma reunião com investidores em pouco tempo, então decide voltar aos seus tempos de bayesiana old school e analisar os dados utilizando prioris conjugadas. Ela supõe que a concentração de amido segue uma distribuição normal com parâmetros μ e τ e que as observações feitas por Valciclei são independentes entre si. Ela suspeita que a concentração de amido na pamonha que em torno de 10 mg/L, com desvio padrão de 2 mg/L. Com sua larga experiência na confecção de pamonhas, ela suspeita ainda que o coeficiente de variação da concentração de amido seja em torno de 1=2. Palmirinha tem um quadro em seu escritório, que diz

$$cv = \frac{\sigma}{\mu}.$$

Agora,

- Elicite uma distribuição a priori conjugada consistente com as suspeitas de Palmirinha. Para isso, interprete-as como valores esperados a priori dos parâmetros¹ – isto é, $\mathbb{E}[\mu] = 10$, $\text{Var}(\mu) = 4$ e $\mathbb{E}[\sqrt{\tau}\mu] = 2$ – e compute os hiperparâmetros β_0 , m_0 e λ_0 da Equação(1). Suponha também que $\alpha_0 = 2$.
- Com os dados anotados por Valciclei, é possível computar a distribuição *a posteriori* de μ e τ ? Justifique.
- Em caso afirmativo, ajude Palmirinha a encontrar $a, b \in \mathbb{R}$, $a < b$ de modo que $\Pr(\mu \in (a, b) \mid \mathbf{x}) = 0.95$.

- $\alpha_0 = 2$, $\beta_0 = ?$, $m_0 = 10$ e $\lambda_0 = ?$
 $E[\mu] = 10$, $\text{Var}(\mu) = 4$ e $E[\sqrt{\tau}\mu] = 2$

$$E[X] = E[E[X|Y]]$$

$$\text{Var}(X) = \text{Var}(E[X|Y]) + E[\text{Var}(X|Y)]$$

$$\mu|\tau \sim N(m_0, \lambda_0\tau)$$

$$E[\mu|\tau] = m_0$$

$$E[\mu] = E[E[\mu|\tau]] = E[m_0] = m_0$$

$$m_0 = 10$$

$$\text{Var}(\mu) = \text{Var}(E[\mu|\tau]) + E[\text{Var}(\mu|\tau)]$$

$$= \cancel{\text{Var}(m_0)} + E\left[\frac{1}{\lambda_0\tau}\right] = \frac{1}{\lambda_0} E\left[\frac{1}{\tau}\right]$$

$$\tau \sim \text{Gamma}(\alpha_0, \beta_0)$$

$$\frac{1}{\tau} \sim \text{GammaInverse}(\alpha_0, \beta_0)$$

$$= \frac{1}{\lambda_0} \frac{\beta_0}{\alpha_0 - 1} = \frac{\beta_0}{(2 - 1)\lambda_0} = 4$$

$$\beta_0 = 4\lambda_0$$

¹As leis de esperança e de variância totais podem ser adequadas; veja [?, Seção 9.6].

$$E[E[\sqrt{\tau}\mu|\tau]] = E[\sqrt{\tau}E[\mu|\tau]] = m_0E[\sqrt{\tau}] = 2$$

$$\begin{aligned}
E[\sqrt{\tau}] &= \int_0^\infty \sqrt{\tau} E[\tau] d\tau \\
&= \frac{\beta_0^{\alpha_0}}{\Gamma(\alpha_0)} \int_0^\infty \tau^{\frac{1}{2}} \tau^{\alpha_0-1} e^{-\beta_0\tau} d\tau \\
&= \frac{\beta_0^{\alpha_0}}{\Gamma(\alpha_0)} \int_0^\infty \underbrace{\tau^{(\alpha_0+\frac{1}{2})-1} e^{-\beta_0\tau}}_{\text{gamma}(\alpha_0+\frac{1}{2}, \beta_0)} d\tau \\
&= \frac{\beta_0^{\alpha_0}}{\Gamma(\alpha_0)} \frac{\Gamma(\alpha_0 + \frac{1}{2})}{\beta_0^{\alpha_0+\frac{1}{2}}}
\end{aligned}$$

Sabendo que $\alpha_0 = 2$:

$$= \frac{1}{\beta_0^{\frac{1}{2}}} \frac{\Gamma(2 + \frac{1}{2})}{\Gamma(2)}$$

$$\Gamma(2) = (2-1)! = 1$$

$$= \Gamma(\frac{5}{2}) = \frac{3}{2}\Gamma(\frac{3}{2}) = \frac{3}{4}\Gamma(\frac{1}{2}) = \frac{3\pi}{4}$$

$$E[E[\sqrt{\tau}\mu|\tau]] = \frac{3\sqrt{\pi}}{4} \frac{m_0}{\beta_0^{\frac{1}{2}}} = 2$$

Sabendo que $m_0 = 10$:

$$\frac{3\sqrt{\pi}}{4} \frac{10}{\sqrt{\beta_0}} = 2$$

$$\frac{3\sqrt{\pi}}{2} \frac{5}{\sqrt{\beta_0}} = 2$$

$$15\sqrt{\pi} = 4\sqrt{\beta_0} \Leftrightarrow \beta_0 = \frac{225\pi}{16}$$

$$\beta_0 = 4\lambda \Rightarrow \lambda = \frac{225\pi}{64}$$

b) Sim, para calcular as distribuições a posteriori, precisamos além dos hiper-parâmetros, a média e a variância, que foram dadas.


c) $\mu_{\bar{x}} \sim t - student(v, M, \sigma)$

$$T/\sqrt{\sigma} + M = \mu_{\bar{x}}$$

$$T = (\mu_{\bar{x}} - M)\sqrt{\sigma} \sim t(v)$$

$$P(a < \mu < b | \underline{x}) = 0.95$$

$$P(a - M)\sqrt{\sigma} < \underbrace{(\mu - M)\sqrt{\sigma}}_{t\text{-student}(v)} < (b - M)\sqrt{\sigma}$$



$$(a - M)\sqrt{\sigma} = \text{CumulativeInverse } t - \text{Student}(v)[2, 5\%]$$

$$(b - M)\sqrt{\sigma} = \text{CumulativeInverse } t - \text{Student}(v)[97, 5\%]$$

$$a = \frac{t_{2,5}}{\sqrt{\sigma}} + M$$

$$b = \frac{t_{97,5}}{\sqrt{\sigma}} + M$$

Visto que $\alpha_0 = 2$ e $n = 10$:

$$v = 2\alpha_0 + n = 2 * 2 + 10 = 14$$

$$M = \frac{\lambda_0 m_0 + n\bar{x}}{\lambda_0 + n}$$

Visto que $\bar{x}_n = 8.307849$, $\lambda_0 = \frac{225\pi}{64}$

$$M = \frac{\frac{225\pi}{64} * 10 + 10 * 8.307849}{\frac{225\pi}{64} + 10}$$

$$M = \frac{11.04466 * 10 + 83.07849}{11.04466 + 10} = \frac{193,52509}{21.04466} \approx 9.19$$

$$\sigma^2 = \frac{\beta}{(\lambda_0 + n)(\alpha_0 + \frac{n}{2})}$$

Como foi visto na questão 2:

$$\beta = \beta_0 + \frac{1}{2} \left(\sum_{i=1}^n x_i^2 + \lambda_0 m_0^2 - \frac{(\lambda_0 m_0 - \sum_{i=1}^n x_i)^2}{\lambda_0 + n} \right) = \beta_0 + \frac{1}{2} s_n^2 (n-1) + \frac{n\lambda_0(\bar{x} - m_0)^2}{2(\lambda_0 + n)}$$

Substituindo os valores:

$$\beta = \frac{225\pi}{16} + \frac{7.930452 * 9}{2} + \frac{10 \frac{225\pi}{64} (8.307849 - 10)^2}{2(21.04466)}$$

$$\beta = 44.1786 + 35.687034 + \frac{\frac{2250\pi}{64} (2.8633)}{42.08932} = 44.1786 + 3.965226 + \frac{316.25}{42.08932}$$

$$\beta = 44.1786 + 35.687034 + \frac{316.25}{42.08932} = 44.1786 + 3.965226 + 7.5137 \approx 87.379334$$

$$\frac{1}{\sigma^2} = \frac{87.379334}{(\frac{225\pi}{64} + 10)(2 + 5)} = \frac{87.379334}{(21.04466)(7)} = \frac{87.379334}{147.31262} \approx 0.5931$$

$$\frac{1}{\sigma} \approx 0.77$$

Então temos uma distribuição $t \sim T - Student(14, 9.19, \frac{1}{0.77})$

Pela tabela da distribuição t-student, $t_{2.5}$ e $t_{97.5}$ para $v = 14$ é: 2.14479:

Agora podemos calcular a e b :

$$a \approx -2.14479 * 0.77 + 9.19 = -2.7854 + 9.19 = 7.5385$$

$$b \approx 2.14479 * 0.77 + 9.19 = 2.7854 + 9.19 = 10.841$$

1 Referência Bibliográfica

Degroot, Schervish. Probability and Statistics 4th Edition, 2011.