

Trabalho II: o algoritmo EM.

Disciplina: Inferência Estatística
Aluno: Iara Cristina Mescua Castro
Curso: Matemática Aplicada

27 de setembro de 2022

Data de Entrega: 28 de Setembro de 2022.

Questões

1. Defina claramente todos os passos do algoritmo EM (faça um glossário de termos se precisar);
2. **Um exemplo motivador:** Suponha que temos duas moedas, Moeda 1 e Moeda 2 de modo que $\Pr(\text{Cara} \mid \text{Moeda} = 1) = p_1$ e $\Pr(\text{Cara} \mid \text{Moeda} = 2) = p_2$; Suponha agora que fazemos o seguinte experimento:
 - (i) Selecionamos uma moeda aleatoriamente com probabilidade $1/2$;
 - (ii) Lançamos a moeda selecionada m vezes;
 - (iii) Repetimos (i) e (ii) n vezes.

Podemos representar os dados advindos deste experimento como

$$\begin{array}{cccc} X_{11} & \dots & X_{1m} & M_1 \\ X_{21} & \dots & X_{2m} & M_2 \\ \vdots & \dots & \vdots & \vdots \\ X_{n1} & \dots & X_{nm} & M_n \end{array} "$$

onde os X_{ij} são variáveis Bernoulli que guardam o resultados do lançamento da moeda e $M_i \in \{1, 2\}$ é a variável aleatória que guarda qual moeda foi selecionada na i -ésima rodada do experimento.

Desenvolva um esquema EM para obter o EMV para $\theta = (p_1, p_2)$ quando desconhecemos os valores de M_i , isto é, quando não sabemos que moeda foi escolhida em cada uma das n rodadas.

3. Mostre que a sequência $\theta^{(j)}$ é monotônica e não decrescente com respeito à verossimilhança, isto é,

$$L\left(\theta^{(j+1)}\right) \geq L\left(\theta^{(j)}\right)$$

Dica (fortemente aconselhado): ver exercício 7.31 de Casella & Berger (2002).

4. Discuta a importância do método EM: quando ele é aplicável? Vale sempre a pena? O que o item anterior demonstra sobre o método?

Respostas

1. Do ponto de vista frequentista, pode-se pensar que os dados observados são gerados a partir de variáveis aleatórias X conjuntamente com dados faltantes ou não observados Z .

$Y = (X, Z)$ representa o vetor de dados completos.

Dado os dados observados, x , deseja-se maximizar a função de verossimilhança $L(\theta, x)$. Frequentemente isto não é simples no entanto pode-se simplificar usando as densidades $Y|\theta$ e $Z|x, \theta$. O algoritmo EM faz isso.

Seja $f_x(x|\theta)$ e $f_y(y|\theta)$ as distribuições dos dados observados e os dados completos, respectivamente

$$f_x(x|\theta) = \int f(y|\theta) dz \text{ e } f_{z|x}(z|x, \theta) = \frac{f_y(y|\theta)}{f_x(x|\theta)} \dots \quad (\text{A})$$

$$L(Y|\theta) = L(X, Z|\theta)$$

O objetivo do algoritmo EM é encontrar o máximo de $L(Y|\theta)$ com relação a θ . Seja $\theta^{(t)}$ o máximo obtido na iteração t . $t = 0, 1, 2, \dots$. Define-se por $Q(\theta, \theta^{(0)})$

$$Q(\theta, \theta^{(t)}) = E\{\log L(\theta, Y)\} \quad (1)$$

$$= E\{\log f_y(y|\theta) | x, \theta^{(t)}\} \quad (2)$$

$$= \int [\log f_y(y|\theta)] \log f_{z|x}(z|x, \theta^{(t)}) dz \quad (3)$$

Onde (3) estabelece que z é a única parte aleatória dado $X = x$.

O algoritmo EM é inicializado em $O^{(0)}$ e alterna nos seguintes passos:

- 1) *E STEP*: Calcular $Q(\theta, \theta^{(0)})$.
 - 2) *M STEP*: Maximizar o $Q(\theta, \theta^{(0)})$.
 - 3) Retornar a 1 até convergência.
2. Seja x_j o resultado da j -ésima sequência de tamanho "n"

$$P(x_i) = \frac{1}{2}P(x_i|M_1) + \frac{1}{2}P(x_i|M_2), \quad j = 1, \dots$$

Dada a moeda $M_j \rightarrow$ cada elemento da sequência segue uma distribuição de Bernoulli com probabilidade p_1 ou p_2 .

- O problema é encontrar o EMV de $\theta = (p_1, p_2)$.
- Considere $Y = (Z, \underline{X})$, onde:

$$Y_1 = (Z_1, \underline{X}_1), Y_2 = (Z_2, \underline{X}_2), \dots, Y_n = (Z_n, \underline{X}_n)$$

Z_j é um indicador que identifica de que a moeda é M_1 ou M_2 .

$$\rightarrow Z_j = 0 \Rightarrow M_1 \text{ ou } Z_j = 1 \Rightarrow M_2$$

Logo $Z = (z_1, \dots, z_n)$ corresponde a variável de alocação não observada. Assim a verossimilhança completa pode ser representada por:

$$\log L(\theta, Y) = \sum_{j=1}^n [(1 - z_j) \log P(\underline{X}_j | M_1) + z_j \log P(\underline{X}_j | M_2)]$$

Logo:

$$Q(\theta, \theta^{(t)}) = E\left\{\sum_{j=1}^n [(1 - z_j) \log P(\underline{X}_j | M_1) + z_j \log P(\underline{X}_j | M_2)] | \underline{x}, \theta^{(t)}\right\}$$

$$= E\left\{\sum_{j=1}^n (1 - z_j) [\sum_{k=1}^m x_{jk} \log p_1 + m - \sum_{k=1}^m x_{jk} \log(1 - p_1)] + \sum_{j=1}^n z_j [\sum_{k=1}^m x_{jk} \log p_2 + m - \sum_{k=1}^m x_{jk} \log(1 - p_2)] | \underline{x}, \theta^{(t)}\right\} \dots (\alpha)$$

E-Step

Logo: Maximizar $Q(\theta, \theta^{(t)})$ equivale a maximizar $(\alpha)'$ com relação a $\theta = (p_1, p_2)$ temos que o valor que maximiza α . E dado por:

$$P_1^{(t+1)} = \frac{\sum_{j=1}^n (1 - E(Z_j | \underline{x}, \theta^{(t)})) \sum_{k=1}^m x_{jk}}{m \sum_{j=1}^n (1 - E(Z_j | \underline{x}, \theta^{(t)}))}, \quad (*)$$

$$P_2^{(t+1)} = \frac{\sum_{j=1}^n E(Z_j | \underline{x}, \theta^{(t)}) \sum_{k=1}^m x_{jk}}{m \sum_{j=1}^n E(Z_j | \underline{x}, \theta^{(t)})}, \quad (**)$$

Onde:

$$E(Z_j | \underline{x}, \theta^{(t)}) = \frac{\frac{1}{2} P(x_j | M_1)}{\frac{1}{2} P(x_j | M_1) + \frac{1}{2} P(x_j | M_2)} \quad (***)$$

$$z_j^{(t+1)} = E(z_j | \underline{x}, \theta^{(t)}) = \frac{\hat{p}_2^{\sum_{k=1}^m x_{jk}} (1 - \hat{p}_2)^{m - \sum_{k=1}^m x_{jk}}}{\hat{p}_1^{\sum_{k=1}^m x_{jk}} (1 - \hat{p}_1)^{m - \sum_{k=1}^m x_{jk}} + \hat{p}_2^{\sum_{k=1}^m x_{jk}} (1 - \hat{p}_2)^{m - \sum_{k=1}^m x_{jk}}}$$

Então o algoritmo EM:

- Inicia P_1^0 e P_2^0

E-Step: determina (α') M-Step: encontra a solução $P_1^{(t+1)}$ e $P_2^{(t+1)}$ através de $(*)$, $(**)$, $(***)$.

3. De (A) temos que:

$$\log f_x(x|\theta) = \log f_y(y|\theta) - \log f_{z|x}(z|x, \theta)$$

Assim:

$$E\{\log f_x(x|\theta|x, \theta^{(t)})\} = E\{\log f_y(y|\theta)|x, \theta^{(t)}\} - E\{\log f_{z|x}(z|x, \theta)|x, \theta^{(t)}\} \dots \quad (4)$$

Onde as esperanças são calculadas com relação a $z|x, \theta^{(t)}$.
Logo, de (4) temos que:

$$\log f_x(x|\theta) = Q(\theta|\theta^{(t)}) - H(\theta|\theta^{(t)}) \dots \quad (5)$$

Onde:

$$H(\theta|\theta^{(t)}) = E\{\log f_y(y|\theta)|x, \theta^{(t)}\}$$

A importância de 1 está relacionada a que $H(\theta|\theta^{(t)})$ é maximizada com relação a θ quando $\theta = \theta^{(t)}$

$$\begin{aligned} & H(\theta^{(t)}|\theta^{(t)}) - H(\theta|\theta^{(t)}) \\ &= E\{\log f_{z|x}(z|x, \theta^{(t)}) - \log f_{z|x}(z|x, \theta)\} \\ &= E\left\{-\log \left[\frac{f_{z|x}(z|x, \theta)}{f_{z|x, \theta^{(t)}}} \right] \middle| x, \theta^{(t)}\right\} \\ &= \int -\log \left[\frac{f_{z|x}(z|x, \theta)}{f_{z|x, \theta^{(t)}}} \right] \times f_{z|x}(z|x, \theta^{(t)}) dz \\ &\geq -\log \int f_{z|x}(z|x, \theta^{(t)}) dz = 0 \end{aligned}$$

O último resultado é obtido da desigualdade de Jensen, já que $-\log u$ é estritamente convexa.

Se $\theta \neq \theta^{(t)} \rightarrow H(\theta|\theta^{(t)})$ é menor que $H(\theta^{(t)}|\theta^{(t)})$. Em particular se $O^{(t+1)}$ maximizar $Q(\theta|\theta^{(t)})$ com relação a θ ,

$$\begin{aligned} \log f_x(x|\theta^{(t+1)}) - \log f_x(x|\theta^{(t)}) &\geq 0 \\ \implies L(\theta^{(t+1)}) &\geq L(\theta^{(t)}) \end{aligned}$$

Já que Q cresce quando H decresce.

$$\implies Q(\theta^{(t+1)}|\theta^{(t)}) > Q(\theta^{(t)}|\theta^{(t)})$$